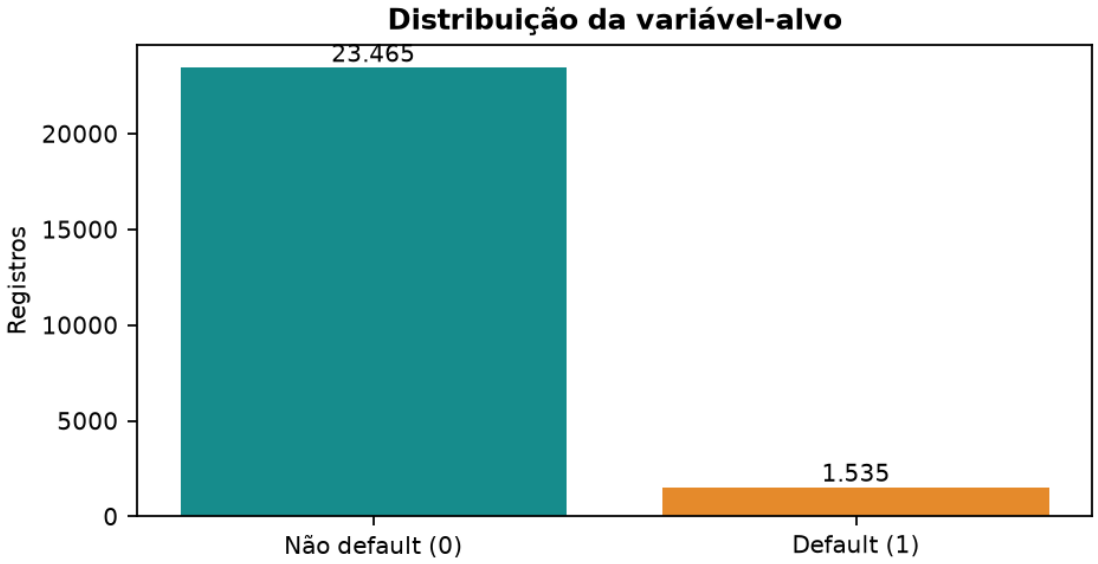
Modelagem e monitoração de risco de crédito

Produção temática | Estimativa de probabilidade de default

Objetivo: construir um fluxo analítico reproduzível para estimar a probabilidade de default (PD), avaliar seu desempenho retrospectivo e propor governança de monitoração para uso contínuo.

Resumo executivo

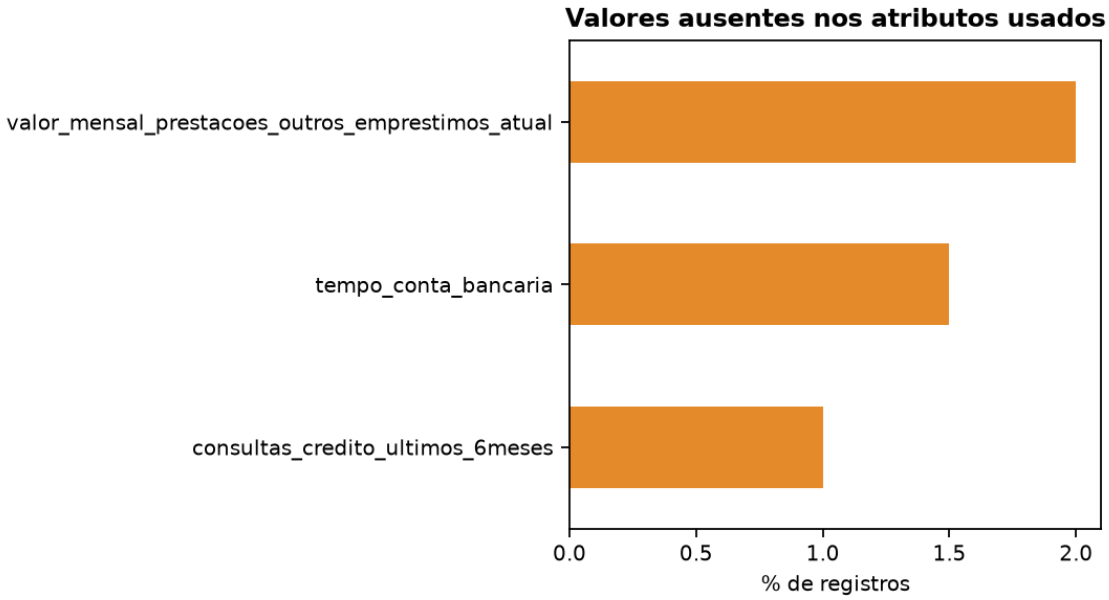
A base analisada contém **25,000** registros e 19 colunas. Foram observados 1,535 defaults (6.14%). O melhor resultado de validação cruzada foi obtido por **Regressão logística**; no teste estratificado, ROC AUC=0.847, Average Precision=0.314 e Brier=0.0489. Este é um estudo retrospectivo, não uma aprovação para decisão automatizada de crédito.



1. Contexto, dados e limitações

A base contém 25 mil solicitações e a variável-alvo marcacao_default (0/1). A taxa observada de default é 6.14%, evidenciando desbalanceamento. Foram encontrados valores ausentes em 3 coluna(s): tempo_conta_bancaria (375), valor_mensal_prestacoes_outros_emprestimos_atual (500), consultas_credito_ultimos_6meses (250). O identificador cliente foi verificado (0 linhas em IDs duplicados) e excluído das predições.

Limitações principais: a base não traz data de observação/originação, definição operacional de default, horizonte da PD, exposição/perda, nem janela de performance; portanto não é possível testar generalização temporal, estimar LGD/EAD, validar estabilidade real, ou confirmar ausência de variáveis posteriores ao evento. O split aleatório estratificado pode superestimar desempenho futuro e a amostra não demonstra representatividade da população de implantação.



2. Análise e engenharia dos dados

O script valida colunas obrigatórias, alvo binário e linhas não vazias; converte campos numéricos com valores inválidos para ausentes e padroniza categorias textuais. Imputação mediana (numéricas) e moda (categóricas), indicadores de ausência numérica, escala para regressão logística e one-hot encoding com categorias inéditas ignoradas são ajustados dentro do pipeline após a separação treino/teste, evitando vazamento de informação. A semente fixa (42), os splits e o pipeline serializado permitem reprodutibilidade.

Foram usadas variáveis de relacionamento e capacidade/conduta de crédito, emprego, condições da proposta e garantia. Foram excluídos cliente (identificador), idade, gênero, estado civil, estado e tipo de cidade por minimização de dados, equidade e redução de proxies geográficos. A seleção é uma decisão inicial de governança que deve ser validada com Jurídico/Compliance e análise de impacto no contexto real.

Comportamento numérico: medianas observadas por classe (descrição, não efeito causal)

Atributo	Ausentes	Mediana sem default	Mediana default
Tempo de relacionamento bancário	375	2.80	2.10
Renda mensal	0	45300.00	40400.00
Outros empréstimos	0	1.00	1.00
Prestações mensais existentes	500	8800.00	10600.00
Uso de crédito	0	40.40	56.20
Consultas de crédito (6 meses)	250	1.00	1.00
Atrasos (12 meses)	0	1.00	2.00
Valor solicitado	0	132000.00	147000.00
Prazo solicitado	0	36.00	36.00

Categorias com maiores taxas observadas entre as que têm ao menos 100 registros; comparação descritiva sujeita a incerteza amostral.

Atributo	Categoria	N	Taxa default
Tipo de emprego	Empresario	3,700	7.43%

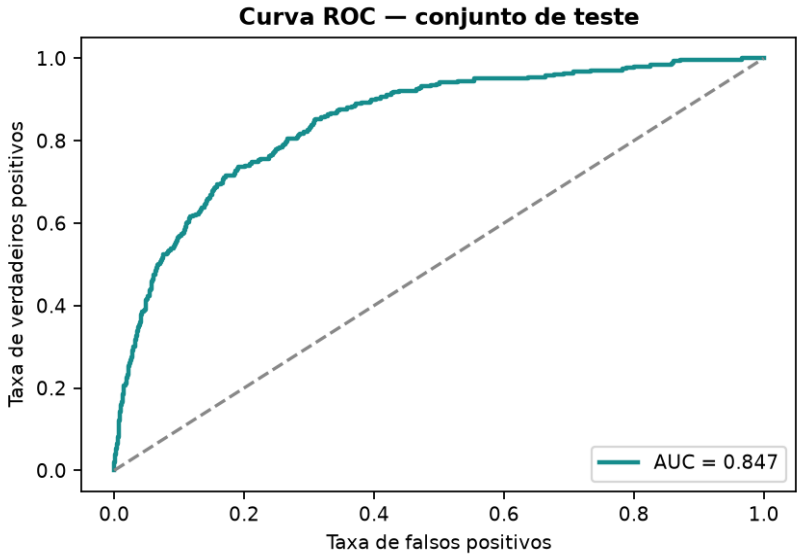
Atributo	Categoria	N	Taxa default
Garantia	Nao	19,535	6.85%
Tipo de emprego	Servidor Publico	3,806	6.70%
Objetivo do empréstimo	Pagamento de Divida	2,470	6.60%
Objetivo do empréstimo	Casamento	3,462	6.50%
Objetivo do empréstimo	Compra de Veiculo	2,475	6.26%
Objetivo do empréstimo	Gasto Pessoal	5,600	6.11%
Objetivo do empréstimo	Expansao de Negocios	2,016	6.05%
Objetivo do empréstimo	Reforma em Imovel	3,291	5.99%
Objetivo do empréstimo	Educacao	2,447	5.97%
Tipo de emprego	Empregado Setor Privado	11,258	5.86%
Objetivo do empréstimo	Emergencia Medica	3,239	5.71%

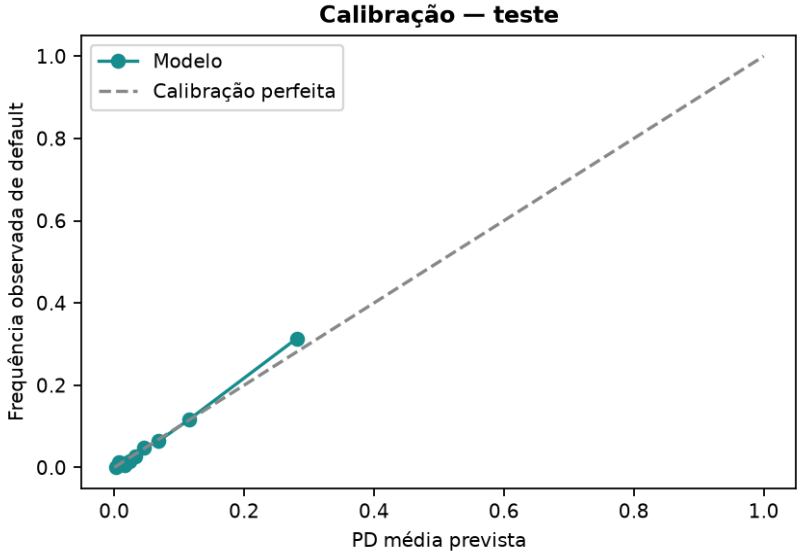
3. Construção e avaliação do modelo

Foram comparadas regressão logística (baseline interpretável) e Random Forest (não linear), com busca de hiperparâmetros em validação cruzada estratificada de 3 folds no treino. O critério de seleção foi Average Precision, mais informativo que acurácia em classes desbalanceadas. O teste final foi separado antes do ajuste (80/20, estratificado, semente 42) e utilizado somente uma vez na avaliação.

Modelo	AP médio CV	Desvio CV	Hiperparâmetros selecionados
Regressão logística	0.322	0.042	C=1.0
Random Forest	0.287	0.035	max_depth=None, max_features=sqrt, min_samples_leaf=10

Métrica (teste)	Resultado	Leitura
ROC AUC	0.847	Ordenação global das classes
Average Precision	0.314	Precisão-revocação; baseline = prevalência
Brier score	0.0489	Erro quadrático das probabilidades (menor é melhor)
Precisão / Recall / F1 (0,50)	0.513 / 0.065 / 0.116	Limiar ilustrativo, não otimizado para decisão



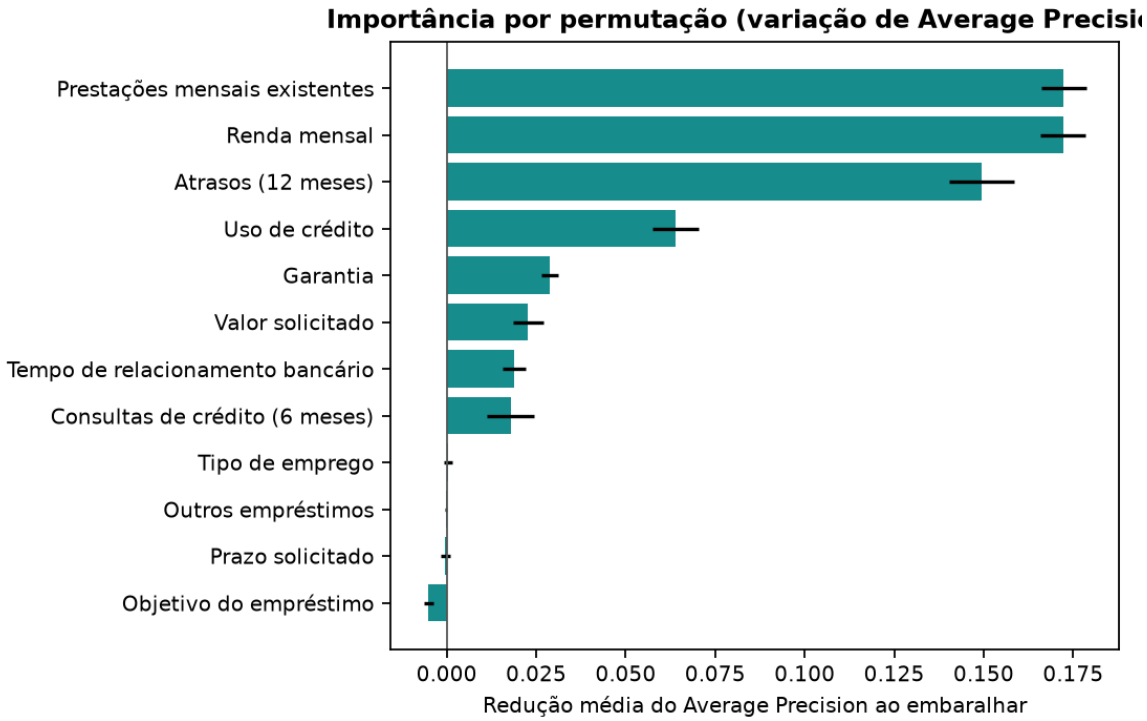


A PD é uma probabilidade estimada, não uma decisão. O limiar 0,50 foi mantido apenas para reportar matriz de confusão/precisão/recall; na implantação, o limiar deve resultar de apetite de risco, custos de erro, capacidade

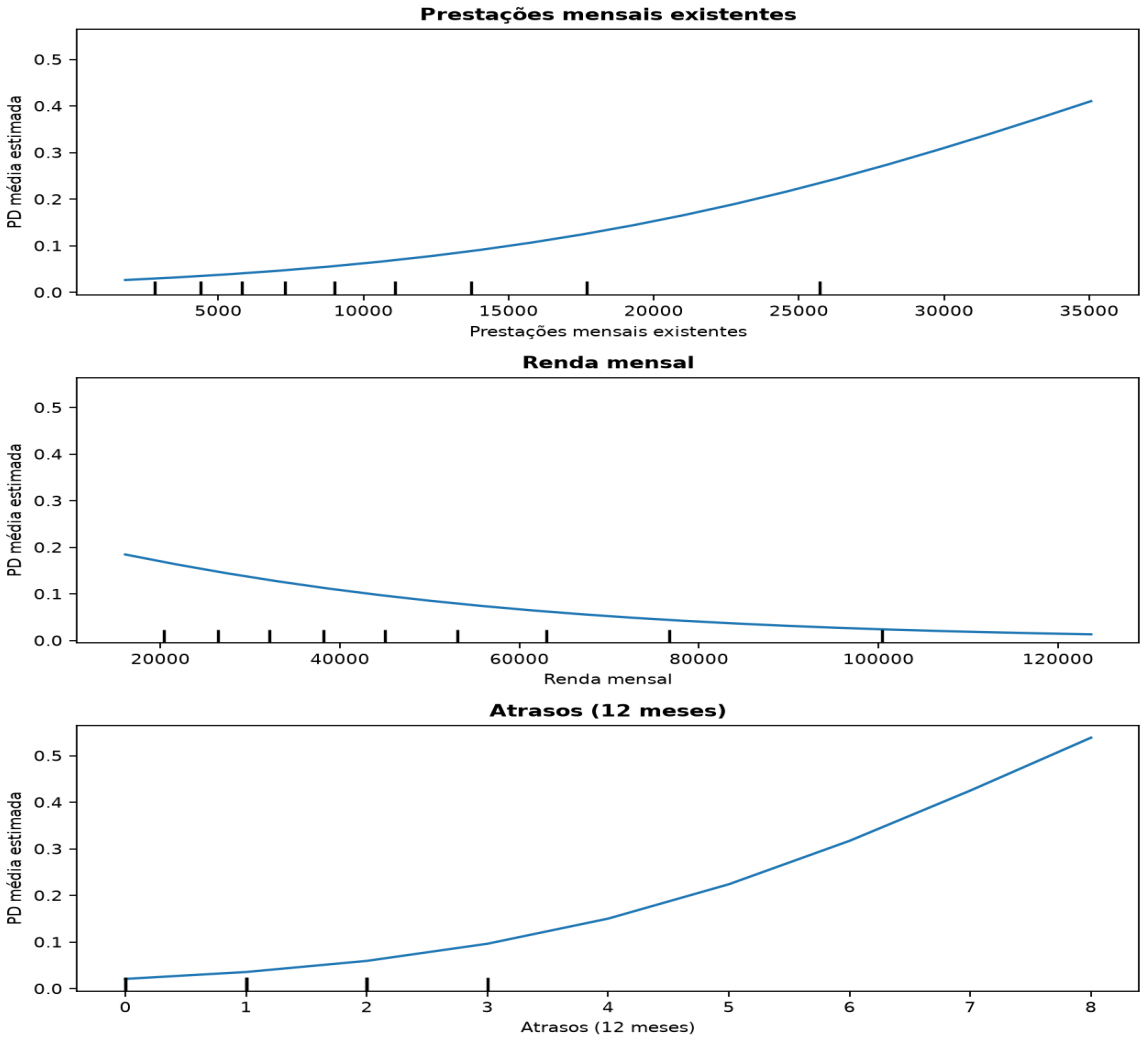
operacional, calibração por horizonte e validação independente. Mesmo sem ponderação de classe, a calibração deve ser validada; calibração pós-treino (por exemplo, isotônica ou sigmoide) pode ser avaliada em amostra separada se necessário.

4. Explicabilidade

A importância por permutação foi calculada no conjunto de teste, medindo a queda média de Average Precision ao embaralhar cada atributo. A medida permite priorizar variáveis globalmente, mas não prova causalidade, pode repartir importância entre atributos correlacionados e não revela sozinha o efeito individual de cada valor. Para explicação local em produção, registrar PD, versão do modelo, entradas autorizadas e uma explicação local validada (por exemplo, SHAP) com trilha de auditoria; revisar explicações e resultados por grupos de forma juridicamente apropriada.



Os gráficos de dependência parcial abaixo mostram como a PD média estimada varia ao longo dos valores dos atributos numéricos mais relevantes, mantendo em média os demais atributos da amostra. São efeitos associativos do modelo e podem ser enganosos quando há forte correlação entre atributos.



5. Estratégia de monitoração contínua

Camada	Métricas / frequência	Sinal e ação sugerida
Qualidade de dados	Esquema, tipos, ausências, faixa, categorias novas; pipeline	Falha crítica de schema/ausência ou faixa impossível: bloquear lote e inves
Estabilidade	PSI para PD e atributos; mensal (dados de score semanais)	PSI < 0,10 baixo; 0,10–0,25 alerta; ≥0,25 crítico; investigar causa e impact
Desempenho	ROC AUC, AP, recall/precisão em limiar vigente, Brier, calibração, lift	Queda > 5 pp AUC, 8 pp AP ou 25% do baseline, ou quebra do limite de ris
Equidade / operação	Métricas por grupos legalmente permitidos, cobertura, latência, rejeição	Diferenças persistentes ou taxa de rejeição anormal: revisar política e mitigar e escalar a g

PSI de treino versus teste fornecido é somente uma referência ilustrativa do split aleatório, não uma medição de drift temporal. Na operação, congelar uma população de referência (treino/validação aprovada), versionar bins e calcular PSI por janela. Garantir amostra mínima e número de defaults antes de interpretar métricas; acompanhar resultados com atraso de maturação do default. Retreino não deve ser automático: gatilhos abrem investigação, validação, aprovação e comparação champion/challenger antes de promover versão.

PSI ilustrativo (treino versus teste, split aleatório)

Atributo	PSI
Valor solicitado	0.0033
Uso de crédito	0.0020
Prazo solicitado	0.0017

Atributo	PSI
Prestações mensais existentes	0.0016
Consultas de crédito (6 meses)	0.0013

6. Arquitetura operacional proposta

Ingestão/contratos: fonte versionada, validação de schema e qualidade; **features:** transformações reutilizáveis e versionadas; **treino/validação:** pipeline, split temporal, tuning, calibração e aprovação; **registro:** artefato do modelo, versão de dados/código, hiperparâmetros e métricas em registry e armazenamento de objetos; **serving:** batch/API com score, identificador pseudonimizado e explicação; **monitoração:** tabelas históricas de qualidade, drift e performance, painel e alertas. Orquestração em DAG (Airflow/Prefect), CI/CD, controle de acesso, criptografia, retenção e auditoria. Escalar por processamento em lotes, armazenamento colunar e workers paralelos; preservar reprodutibilidade por imagem/container imutável.

Conclusão e recomendações

O fluxo entrega baseline reproduzível, comparação de algoritmos, PD por registro de teste, métricas e artefatos de explicabilidade/estabilidade. Antes de qualquer uso em decisão: definir default e horizonte; conseguir coorte temporal e dados de resultado; validar calibração, estabilidade, equidade e impacto econômico; revisar variáveis e limiar; realizar validação independente, aprovação de governança e plano de contingência. Até então, utilizar apenas como protótipo analítico, com revisão humana e sem automatizar concessão/recusa.

Artefatos associados: código-fonte producao_tematica.py, pipeline_serializado.joblib, metricas.json, predicoes_teste.csv, importancia_permutacao.csv, perfil_numerico.csv, perfil_categorico.csv e psi_referencia.csv. A execução registra versão das bibliotecas e parâmetros no arquivo metricas.json.